## Tarea Neo4J

## Importación de datos

Para empezar, una vez descargado los datos los exporto empleando el comando tar.

```
PS C:\Users\Vespertino> tar -xvf Downloads/yelp_dataset.tar
x Dataset_User_Agreement.pdf
x yelp_academic_dataset_business.json
x yelp_academic_dataset_checkin.json
x yelp_academic_dataset_review.json
x yelp_academic_dataset_tip.json
x yelp_academic_dataset_tip.json
x yelp_academic_dataset_user.json
PS C:\Users\Vespertino>
```

Una vez exportados, con un programa de Python cambio su formato de json a csv.

```
C:\Users\Vespertino>py json_to_csv_converter.py yelp_academic_dataset_business.json

C:\Users\Vespertino>py json_to_csv_converter.py yelp_academic_dataset_checkin.json

C:\Users\Vespertino>py json_to_csv_converter.py yelp_academic_dataset_review.json

C:\Users\Vespertino>py json_to_csv_converter.py yelp_academic_dataset_user.json

C:\Users\Vespertino>py json_to_csv_converter.py yelp_academic_dataset_tip.json
```

El primer intento del ejercicio fue empleando solo los primeros 2000 campos de cada csv, pero debido a la falta de relaciones decidí volver a intentarlo usando todos los datos.

Por culpa del enorme tamaño de "user" y "review", me he visto obligado a recortar estos dos csv a sus primeros 100000 para este intento.

```
PS C:\Users\WINDOWS 11\Documents\csv> Get-Content ".\yelp_academic_dataset_review.csv" | select -First 100000 | Out-File ".\yelp_academic_dataset_review_rec ortado2.csv"

PS C:\Users\WINDOWS 11\Documents\csv> Get-Content ".\yelp_academic_dataset_review_rec ortado2.csv"

PS C:\Users\WINDOWS 11\Documents\csv> Get-Content ".\yelp_academic_dataset_review_rec ortado2.csv" | select -First 100000 | Out-File ".\yelp_academic_dataset_review_user2.csv"
```

Mando los archivos recortados al interior del contenedor empleando docker cp.

```
PS C:\Users\Vespertino\csv> docker cp ".\out" d80473fd6a79:/var/lib/neo4j/import/.
Successfully copied 58.2MB to d80473fd6a79:/var/lib/neo4j/import/.
PS C:\Users\Vespertino\csv> _
```

Lo siguiente ha sido importar los datos de la siguiente forma dentro de neo4j, y tras ello he creado las siguientes relaciones.

```
LOAD CSV WITH HEADERS FROM 'file:///yelp_academic_dataset_business_out.csv' AS row
CREATE (n:Business)

SET n = row

LOAD CSV WITH HEADERS FROM 'file:///yelp_academic_dataset_checkin_out.csv' AS row
CREATE (n:Checkin)

SET n = row

LOAD CSV WITH HEADERS FROM 'file:///yelp_academic_dataset_review_out.csv' AS row
CREATE (n:Review)

SET n = row

LOAD CSV WITH HEADERS FROM 'file:///yelp_academic_dataset_user_out.csv' AS row
CREATE (n:User)

SET n = row

LOAD CSV WITH HEADERS FROM 'file:///yelp_academic_dataset_tip_out.csv' AS row
CREATE (n:User)

SET n = row
```

Los Usuarios escriben Reviews que están destinadas a Negocios

```
MATCH (r:Review),(u:User)

WHERE r.user_id = u.user_id

CREATE (u)-[:OPINA]->(r)

MATCH (b:Business),(r:Review)

WHERE b.business_id = r.business_id

CREATE (r)-[:Califica]->(b)
```

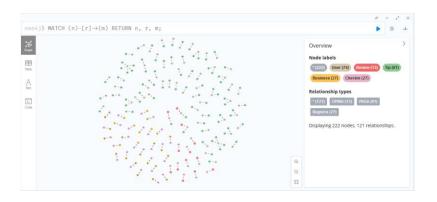
#### Los Negocios realizan Checkins

```
MATCH (b:Business),(c:Checkin)
WHERE b.business_id = c.business_id
CREATE (b)-[:Registra]->(c)
```

#### Y los Usuarios escriben Consejos

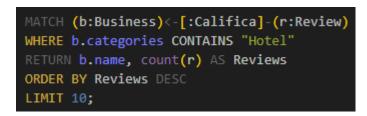
```
MATCH (t:Tip),(u:User)
WHERE t.user_id = u.user_id
CREATE (u)-[:PAGA]->(t)
```

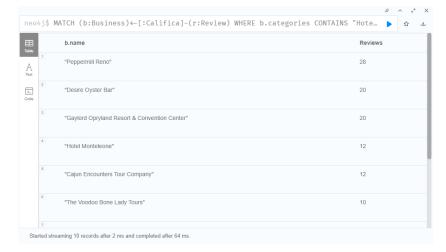
(la relación es "PAGA" porque pensaba que se refería a Tip de "propina")



# Aplicación de Viaje

Encuentra los 10 hoteles con mayor número de reviews.





Encuentra los 10 usuarios con un número mayor de reviews realizadas.

```
MATCH (u:User)-[:OPINA]->(r:Review)
RETURN u.name, count(r) AS Reviews
ORDER BY Reviews DESC
LIMIT 10;
```



# Consultoría empresa de viajes

A partir de aquí es posible que salgan errores debido a la falta de datos de User y Review. Estas son las siguientes consultas.

1. Encuentra los 50 usuarios con mayor número de reviews que han hecho una review del hotel Bellagio Hotel.

He cambiado el Bellagio por el Reno para mejor funcionamiento.



2. Buscar todos los hoteles que estos usuarios han hecho una review, no vale introducir los usuarios en el Where de manera manual.

```
MATCH (hotel:Business {name: "Peppermill Reno"}) ← [:Califica] - (r:Review) ← [:OPINA] - (u:User)

WITH u

MATCH (u) - [:OPINA] → (r2:Review) - [:Califica] → (hotel2:Business)

WHERE hotel2.categories CONTAINS "Hotel" and hotel2.name ◇ "Peppermill Reno"

WITH hotel2, count(r2) AS Reviews

ORDER BY Reviews DESC

LIMIT 50

RETURN hotel2.name AS Hotel, Reviews

(no changes, no records)
```

Si se permite el mismo hotel la consulta funciona.



# 3. Obtén el hotel con mayor número de reviews de los usuarios obtenidos en el apartado 1 de esta sección

```
1 MATCH (hotel:Business {name:"Peppermill Reno"})←[:Califica]−(r:Review)←[:OPINA]−
(u:User)
2 WITH u
3 MATCH (u)−[:OPINA]→(r2:Review)−[:Califica]→(hotel2:Business)
4 WHERE hotel2.categories CONTAINS "Hotel" AND hotel2.name ◇ "Peppermill Reno"
WITH hotel2, count(r2) AS Reviews
0 ORDER BY Reviews DESC
7 LIMIT 1
8 RETURN hotel2.name AS Hotel, Reviews;
9 (no changes, no records)
```

Como en el apartado anterior, si se elimina la exclusión, funciona.

